

train.py — XGBoost 모델 학습

1. 역할

공정(PR/SD) × 불량유형별로 XGBoost 이진 분류 모델을 학습하고 저장합니다. analyze.py 와 kafka_manager_shap.py 가 사용할 모델과 스케일러를 생성합니다.

구분	설명
입력	dataset/1.base_data/json/ 의 불량 JSON 파일 전체
출력	result_cause/models/ 의 XGBoost 모델 18개
부산물	result_cause/scalers/ 의 StandardScaler 2개 (PR/SD)

2 실행 방법

```
cd models/4.cause
python train.py
```

처음 한 번만 실행하면 됩니다. 데이터가 추가되었거나 모델을 갱신하고 싶을 때 다시 실행합니다.

3. 내부 동작 흐름

순서	동작	설명
①	JSON 파싱	모든 JSON 파일을 읽어 PR/SD 로 분리, 제외 파일은 skipped_files.txt 에 기록
②	스케일러 학습	공정별 센서값의 평균·표준편차를 계산해 StandardScaler 저장
③	모델 학습	불량유형별 이진 분류 XGBoost 학습 (클래스 불균형 자동 보정)
④	모델 저장	result_cause/models/PR_미납.json 형태로 저장

4. 입력 피처 구성

센서 5개 × (평균값, 최대값) = 피처 10개를 사용합니다.

인덱스	피처명	설명
0	temperature_mean	온도 시퀀스 평균
1	temperature_max	온도 시퀀스 최대
2	humidity_mean	습도 시퀀스 평균
3	humidity_max	습도 시퀀스 최대
4	vibration_mean	진동 시퀀스 평균
5	vibration_max	진동 시퀀스 최대
6	acceleration_mean	가속도 시퀀스 평균
7	acceleration_max	가속도 시퀀스 최대
8	noise_mean	소음 시퀀스 평균
9	noise_max	소음 시퀀스 최대

5. 핵심 함수 설명

parse_json(path)

JSON 파일 하나를 읽어 피쳐 10개와 불량 ID 집합을 반환합니다. 아래 경우에 해당하면 제외합니다.

제외 조건	이유
JSON 파일 형식 오류	읽을 수 없어 피쳐 생성 불가
파일명이 PR/SD 로 시작하지 않음	공정 구분 불가
불량 어노테이션 없음	정상 이미지 — 불량 원인 분석 불필요
sensor_data 없음	피쳐 생성 불가
sensor_sequence 없음	피쳐 생성 불가

train_one(X, y)

불량 하나에 대한 XGBoost 이진 분류기를 학습합니다.

```
clf = XGBClassifier(  
    n_estimators=100, # 결정 트리 100개 순차 학습  
    max_depth=3, # 각 트리 최대 깊이  
    scale_pos_weight=..., # 클래스 불균형 자동 보정  
    base_score=0.5, # XGBoost 3.x + SHAP 호환성 버그 우회  
)
```

scale_pos_weight 란? 불량 샘플이 정상 샘플보다 훨씬 적을 때, 모델이 '항상 정상'으로 예측하는 것을 막기 위해 불량 샘플에 더 높은 가중치를 부여합니다. 값 = 정상 샘플 수 ÷ 불량 샘플 수

6. 출력 결과

경로	내용
result_cause/models/PR_미납.json	PR 공정 미납 XGBoost 모델
result_cause/models/PR_납부족.json	PR 공정 납부족 XGBoost 모델
result_cause/models/SD_냉납.json	SD 공정 냉납 XGBoost 모델
result_cause/models/... (총 18개)	공정 × 불량유형별 모델
result_cause/scalers/PR_scaler.pkl	PR 공정 StandardScaler
result_cause/scalers/SD_scaler.pkl	SD 공정 StandardScaler
result_cause/skipped_files.txt	파싱에서 제외된 파일 목록 및 이유

skipped_files.txt 예시

제외된 파일 목록 (총 928개)

```
=====
PR_NOR_NM_A_20250807_00001.json # 불량 어노테이션 없음 (정상 이미지)
SD_NOR_NM_A_20250807_00002.json # 불량 어노테이션 없음 (정상 이미지)
...
```

7. XGBoost 모델 구조

각 불량유형마다 독립적인 이진 분류기(Binary Classifier)를 학습합니다.

PR_미납 모델: 입력(센서 피쳐 10개) → '미납 있다(1) / 없다(0)' 예측
PR_납부족 모델: 입력(센서 피쳐 10개) → '납부족 있다(1) / 없다(0)' 예측
SD_냉납 모델: 입력(센서 피쳐 10개) → '냉납 있다(1) / 없다(0)' 예측

... (총 18개 모델)

모델 파일은 XGBoost 공식 JSON 포맷으로 저장됩니다. 사람이 직접 열어볼 수 있으며 버전 호환성이 좋습니다.

본 문서는 `models/4.cause/train.py` 기준으로 작성되었습니다.